Universidad de Antioquia

Facultad de Ciencias Exactas y Naturales

Examen 1: Fundamentos en ciencia de datos (FCD) 22 Julio 2025

- Nombre :

- E-mail :

- Profesor laboratorio :

Instrucciones del Examen

Este examen debe realizarse de manera estrictamente **individual**. Lea atentamente las siguientes reglas antes de comenzar:

- **Tiempo límite:** La duración del examen es de 90 minutos (1 hora 30 minutos).
- **Formato de respuestas:**
  - Preguntas con **círculos** (◯) permiten seleccionar **una única respuesta**.
  - Preguntas con **cuadros** [□] permiten seleccionar **múltiples respuestas**.
- **Uso de materiales externos:** Está completamente prohibido el uso de libros, apuntes, dispositivos electrónicos como calculadoras, teléfonos o computadoras, consultas a otras personas o cualquier forma de colaboración.

Formato del examen:

- Responda directamente en la hoja del examen en los espacios designados. Asegúrese de que sus respuestas sean legibles y definitivas; las respuestas ambiguas o tachadas pueden no ser evaluadas.

Normas de conducta:

- Cualquier intento de fraude o comunicación con otros estudiantes resultará en la anulación inmediata del examen.
- En caso de dudas, consulte únicamente con el supervisor del examen.

Entrega: Al finalizar el tiempo, entregue el examen de inmediato. No se aceptarán exámenes fuera del tiempo asignado.

Lea cuidadosamente cada pregunta y conteste con claridad. ¡Éxito en su examen!

1. (31 puntos) Verdadero o Falso

(a) (3.0 pt) El resultado de un experimento aleatorio puede no coincidir con lo que predice la probabilidad teórica.

◯ Verdadero ◯ Falso

(b) (3.0 pt) Imagina que estás lanzando un solo dado. Piensa en dos eventos posibles:

- Evento A: que salga un número par.
- Evento B: que salga un número impar.

Evidentemente, si ocurre uno de ellos, el otro no puede ocurrir al mismo tiempo. Es decir, no puedes sacar un número par e impar en la misma tirada. Estos eventos son mutuamente excluyentes porque se excluyen entre sí. Ahora bien, cuando dos eventos no pueden pasar al mismo tiempo, la probabilidad de que ambos ocurran juntos no tiene sentido práctico: no pueden ocurrir juntos.

Basado en lo anterior, responde: si dos eventos son mutuamente excluyentes, entonces su probabilidad conjunta es igual al producto de sus probabilidades individuales.

◯ Verdadero ◯ Falso

(c) (3.0 pt) Supón que tienes un arreglo de resultados booleanos:

```
make_array(True, False, True, True, False)
```

Si calculas el promedio de este arreglo con NumPy usando np.average, ¿qué estás obteniendo?, ten presente que en Python, True se interpreta como 1 y False como 0.

Basado en lo anterior, responde, el promedio de un arreglo booleano en NumPy representa la fracción de valores que son verdaderos.

◯ Verdadero ◯ Falso

(d) (3.0 pt) La distancia total de variación (TVD) se puede usar para comparar distribuciones de frecuencias relativas en variables categóricas (por ejemplo, colores, respuestas de encuesta, etc.).

◯ Verdadero ◯ Falso

(e) (3.0 pt) Imagina que haces una encuesta a dos grupos de estudiantes preguntando por su sabor favorito de helado. Obtienes dos distribuciones: una para el Grupo A y otra para el Grupo B. Ambas distribuciones muestran las proporciones de personas que prefieren chocolate, vainilla o fresa. Aunque las respuestas son categorías, puedes compararlas: por ejemplo, puedes ver si al Grupo A le gusta mucho más la vainilla que al Grupo B. Para cuantificar estas diferencias, usamos una medida llamada distancia de variación total, que nos dice qué tanto se parecen o se diferencian dos distribuciones categóricas.

Basado en lo anterior, responde: Si una tabla contiene datos categóricos, no se puede calcular la distancia de variación total entre dos distribuciones basadas en ella.

◯ Verdadero ◯ Falso

(f) (3.0 pt) La función sample_proportions en python, devuelve una tabla.

◯ Verdadero ◯ Falso

(g) (3.0 pt) Un grupo de biólogas marinas quiere investigar si los sonidos de los barcos afectan la migración de las ballenas jorobadas. Para ello, observan dos grupos de ballenas: un grupo que habita una zona con mucho tráfico marítimo y otro grupo que vive en una región más tranquila. Al final de la temporada, notan que las ballenas en la zona ruidosa migraron más tarde.

Basándose en esta comparación, las investigadoras concluyen que el ruido de los barcos causa el retraso en la migración. Sin embargo, no asignaron a las ballenas a cada zona al azar: simplemente observaron dónde vivía cada grupo. Por lo tanto, podrían haber otros factores diferentes entre ambas zonas (como temperatura, comida, o depredadores) que estén afectando el comportamiento.

Basado en lo anterior, responde: El uso de un grupo de control en un experimento permite establecer causalidad sin necesidad de aleatorización.

◯ Verdadero ◯ Falso

(h) (3.0 pt) En una prueba de hipótesis, el valor-p representa la probabilidad de obtener resultados tan extremos como los observados, asumiendo que la hipótesis nula es verdadera. Por ejemplo, si realizamos una prueba y obtenemos un valor-p de 0.01, esto significa que hay solo un 1% de probabilidad de observar datos como los nuestros si la hipótesis nula fuera cierta.

En una prueba de hipótesis, un valor-p bajo (por ejemplo, menor a 0.05) indica evidencia en contra de la hipótesis nula.

◯ Verdadero ◯ Falso

Selección multiple:

(i) (7.0 pt) Para investigar si un nuevo suplemento mejora la concentración durante el estudio, se asigna aleatoriamente a un grupo de estudiantes a tomar el suplemento (grupo de tratamiento), y a otro grupo se le da una pastilla sin efecto activo (grupo de control). Luego se mide el desempeño de ambos grupos en una tarea de concentración.

¿Cuál es la razón principal por la que esta estrategia puede ayudar a establecer una relación causal entre el suplemento y la concentración?

- ☐ Porque al incluir un grupo control, se asegura que todos los estudiantes tomen el suplemento.
- ☐ Porque al usar una tarea de concentración, se puede medir con precisión el rendimiento individual.
- ☐ Porque la asignación aleatoria reduce la posibilidad de que otros factores expliquen las diferencias observadas.
- ☐ Porque comparar grupos permite ver si hay alguna diferencia, sin importar cómo se asignaron.

2. (24 puntos) Completa el espacio en blanco

Una tarde en la biblioteca, Clara, Julián y Mateo están preparando una presentación grupal. Tienen tres libros distintos que van a consultar para su proyecto:

- un libro de Ciencia Ficción ,
- un libro de Historia ,
- y un libro de Biología .

Cada vez que ensayan la presentación, colocan los tres libros en la mesa en un orden aleatorio, uno al lado del otro, para decidir con cuál empezar.

Julián, que ha tomado el curso Fundamentos en ciencia de datos, se pregunta qué tan probable es que cierto libro aparezca en determinada posición, o que el orden de exposición favorezca algunas combinaciones sobre otras. Deciden analizar esta situación como un problema de probabilidad.

(a) (12.0 puntos) Cálculo de probabilidades

Responde las siguientes preguntas sobre el experimento:

(a) (3.0 pt) Representemos los libros por sus iniciales:

- **C** para Ciencia Ficción
- **H** para Historia
- **B** para Biología

Escribe el **espacio muestral**, es decir, todas las posibles ordenaciones de los tres libros en la mesa.

(b) (3.0 pt) ¿Cuál es la probabilidad de que el libro de Historia esté en la primera o en la última posición?

(c) (3.0 pt) Si repiten este experimento 360 veces, ¿en cuántas esperarías que el libro de Ciencia Ficción quede exactamente en el centro?

(d) (3.0 pt) ¿Cuál es la probabilidad de que el libro de Biología esté ubicado antes que el de Historia (no necesariamente justo antes)?

El grupo quiere simular cuántas veces el libro de Ciencia Ficción queda en la última posición cuando colocan los tres libros al azar sobre la mesa sin reemplazo. Clara escribe el siguiente código incompleto:

```
import numpy as np
from datascience import *

def simular_libro_cf_final(n):
    libros = make_array("Ciencia Ficción", "Historia", "Biología")
    conteo_exitos = 0

    for _ in np.arange(n):
        # Orden aleatorio sin reemplazo
        muestra = np.random.choice(libros, 3, replace=False)
        if __________:  # (a)
            conteo_exitos += 1

    return conteo_exitos / n
```

(a) (2.0 pt) Completa el espacio **(a)** con una condición lógica que verifique si el libro de Ciencia Ficción está al final de la fila.

Ahora, Julián y Mateo quieren escribir otra simulación, pero esta vez con reemplazo, para estimar con qué frecuencia aparece cada tipo de libro cuando se seleccionan libros al azar muchas veces. El grupo propone el siguiente código incompleto:

```
def simular_frecuencia_libros(n):
    prob_libros = __________   # (b)

    prob_distribution = make_array(prob_libros, __________)   # (c)

    simulated_proportions = __________   # (d)

    num_extracciones = __________ * simulated_proportions.__________   # (e) (f)

    return num_extracciones
```

(b) (1.0 pt) Completa el espacio **(b)** con la probabilidad de seleccionar cada libro (todos tienen la misma probabilidad).

(c) (2.0 pt) Completa el espacio **(c)** con la probabilidad para los otros dos libros (Historia y Biología).

(d) (3.0 pt) Completa el espacio **(d)** con la función adecuada para simular proporciones de muestreo.

(e) (2.0 pt) Completa el espacio **(e)** con el número total de extracciones que se desean simular.

(f) (2.0 pt) Completa el espacio **(f)** con el índice correcto para acceder a la proporción del libro de Ciencia Ficción.

3. (24 puntos) Registro de entrenamientos de Sofía

Cada día, **Sofía** realiza una sesión de entrenamiento y registra cuánto tiempo le toma completar cada rutina. Ella almacena estos datos en una tabla llamada **trainings**, donde cada fila representa una sesión de entrenamiento. A continuación, se muestra un ejemplo de la tabla para 10 dias de entrenmaiento, la tabla total tiene 120 dias de entrenamiento, que no es mostrada en su totalidad :

NumeroActividad	**DiaEntrenamiento**	**Actividad**	**Horas**	**Minutos**
1	Lunes	Pesas	1	22
2	Martes	Natación	2	31
3	Miércoles	Correr	2	38
4	Jueves	Bicicleta Estática	2	33
5	Viernes	Bicicleta Estática	1	21
6	Sábado	Natación	1	42
7	Lunes	Pesas	1	43
8	Martes	Correr	2	39
9	Miércoles	Bicicleta	1	15
10	Jueves	Natación	2	44

Table 1: Ejemplo de tabla de entrenamientos de Sofía

Donde,

- **NumeroActividad**: (`int`) Número de actividad que realizó
- **DiaEntrenamiento**: (`string`) el día de la semana en que se planeó el entrenamiento.
- **Actividad**: (`string`) Actividad que realiza a la semana
- **Minutos**: (`int`) la cantidad de minutos que tomó completar la sesión, redondeado hacia abajo.
- **Segundos**: (`int`) los segundos adicionales después de los minutos completos.

Sofía quiere analizar su entrenamiento y necesita trabajar con la tabla `training`, la cual es un objeto de tipo `datascience`

(a) (2.0 pt) Dada la tabla `training` qué es una tabla de `datascience`, ¿cuál de las siguientes opciones permite seleccionar una columna particular correctamente?

Seleccione **todas** las respuestas correctas.

- ☐ `training.select("Minutos")`
- ☐ `training.column("Minutos")`
- ☐ `training("Minutos")`
- ☐ `training_.("Minutos")`

(b) (2.0 pt) Sofía quiere crear una nueva columna en `training` llamada `"TiempoTotal(min)"` que contenga el tiempo total de cada entrenamiento en **minutos**

Para ello, define la siguiente función:

```
def convertir_a_minutos(horas, minutos):
    return horas * 60 + minutos
```

¿Cuál de las siguientes opciones permite crear correctamente la nueva columna en la tabla usando el método `apply`? Seleccione **una o varias** respuestas correctas.

- ☐ `training.with_column("TiempoTotal(min)", training.apply(convertir_a_minutos, "Horas", "Minutos"))`
- ☐ `training.with_column("TiempoTotal(min)", convertir_a_minutos("Horas", "Minutos"))`
- ☐ `training.apply("TiempoTotal(min)", convertir_a_minutos, "Horas", "Minutos")`
- ☐ `training.apply("TiempoTotal(min)", convertir_a_minutos)`

(c) (2.0 pt) Después de realizar la conversión, Sofía obtiene la siguiente tabla asignándole un nuevo nombre training_process:

NumeroActividad	DiaEntrenamiento	Actividad	Horas	Minutos	TiempoTotal(min)
1	Lunes	Pesas	1	22	82
2	Martes	Natación	2	31	151
3	Miércoles	Correr	2	38	158
4	Jueves	Bicicleta Estática	2	33	153
5	Viernes	Bicicleta Estática	1	21	81
6	Sábado	Natación	1	42	102
7	Lunes	Pesas	1	43	103
8	Martes	Correr	2	39	159
9	Miércoles	Bicicleta	1	15	75
10	Jueves	Natación	2	44	164

Table 2: Ejemplo de tabla de entrenamientos de Sofía, después de transformarla

¿Cuál sería la expresión en Python para calcular el **valor medio** del tiempo total de entrenamiento por actividad? Escriba su respuesta en la línea siguiente:

(d) (2.0 pt) ¿Cuál sería la expresión en Python para calcular el **valor máximo** del tiempo total de entrenamiento por actividad? Escriba su respuesta en la línea siguiente:

(e) (2.0 pt) ¿Cuál sería la expresión en Python para calcular el **valor mínimo** del tiempo total de entrenamiento por actividad?.Escriba su respuesta en la línea siguiente:

(f) (2.0 pt) ¿Cuál de las siguientes expresiones en Python arroja la salida mostrada en la siguiente tabla?

- ☐ `training_process.pivot("Actividad", "DiaEntrenamiento", "TiempoTotal(min)", np.mean)`
- ☐ `training_process.group("Actividad", "DiaEntrenamiento", "TiempoTotal(min)", np.mean)`
- ☐ `training_process.apply("Actividad", "DiaEntrenamiento", "TiempoTotal(min)", np.mean)`
- ☐ `training_process.join("Actividad", "DiaEntrenamiento", "TiempoTotal(min)", np.mean)`

DiaEntrenamiento	Bicicleta	Bicicleta Estática	Correr	Natación	Pesas	Subir Montañas
Jueves	116.0	146.5	152.0	123.333	123.25	84.5
Lunes	137.5	98.0	95.0	124.5	112.667	104.0
Martes	126.333	155.5	111.75	116.0	102.667	66.5
Miércoles	113.167	96.5	136.333	102.5	154.0	106.5
Sábado	124.0	151.0	138.0	101.25	153.0	103.0
Viernes	106.0	107.6	145.0	104.5	90.5	119.667

Table 3: Tiempo total promedio (en minutos) de entrenamiento por actividad y día de la semana

(g) (2.0 pt) Sofía quiere analizar el tiempo total promedio dedicado a cada actividad y ha generado el siguiente gráfico de barras: ¿Cuál de las siguientes opciones en Python genera correctamente el gráfico mostrado? Seleccione **todas** las respuestas correctas.

- ☐ `training_process.select("Actividad", "TiempoTotal(min)").group("Actividad", np.mean).barh("Actividad")`
- ☐ `training_process.select("Actividad", "TiempoTotal(min)").group("Actividad", np.mean).bar("Actividad")`

☐ `training_process.group("Actividad", np.mean).bar("TiempoTotal(min)")`

☐ `training_process.bar("Actividad", "TiempoTotal(min)")`

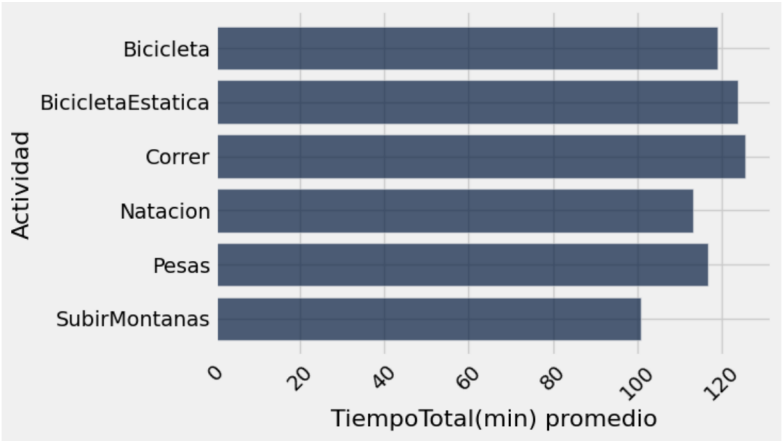

(h) (8.0 pt) Sofía quiere analizar si el tiempo total promedio dedicado a la actividad **Subir Montañas** es consistente con la variabilidad aleatoria o si presenta un patrón significativo. Para ello, debe formular una hipótesis y realizar un análisis estadístico.

Con base en el gráfico, plantee una hipótesis nula ($\mathbf{H}_0$) y una hipótesis alternativa ($\mathbf{H}_A$) para evaluar si el tiempo total de entrenamiento en Subir Montañas es resultado de la aleatoriedad.

Hipótesis Nula ($\mathbf{H}_0$):

Hipótesis Alternativa ($\mathbf{H}_A$):

(i) (2.0 pt) Después de realizar la prueba de permutación, Sofía obtiene un valor p de **0.5**. ¿Qué conclusión se puede sacar a partir de este resultado?

4. (21 puntos) Germinación de semillas

En un experimento de germinación, 200 semillas de maíz fueron tratadas con una nueva hormona vegetal para mejorar la tasa de germinación.

- De las 200 semillas tratadas, 75 germinaron correctamente. - Se esperaba que la tasa de germinación fuera del 50%. Surge la pregunta: ¿Este resultado se debe al azar, o la hormona es realmente menos efectiva de lo esperado?

Estadístico de prueba: - Número de semillas germinadas, de un total de 200, que muestran una mejora significativa tras el tratamiento con hormonas vegetales

(a) (5.0 pt) De las siguientes hipótesis estadísticas, selecciona la que mejor modela este problema:

- ☐ Hipótesis nula (H_0): La proporción de semillas que germinan es igual al 50%. Hipótesis alternativa (H_A): La proporción de semillas que germinan es menor al 50%.
- ☐ Hipótesis nula (H_0): La hormona vegetal no tiene efecto en la tasa de germinación. Hipótesis alternativa (H_A): La hormona vegetal mejora la tasa de germinación.
- ☐ Hipótesis nula (H_0): Todas las semillas tratadas germinarán. Hipótesis alternativa (H_A): Algunas semillas no germinarán.
- ☐ Hipótesis nula (H_0): La tasa de germinación con la nueva hormona es diferente del 50%. Hipótesis alternativa (H_A): La tasa de germinación con la nueva hormona es exactamente 50%.
- ☐ Hipótesis nula (H_0): La hormona reduce la tasa de germinación. Hipótesis alternativa (H_A): La hormona no afecta la tasa de germinación.

(b) (4.0 pt) Se desea evaluar si el tratamiento con la nueva hormona vegetal afecta la tasa de germinación de las semillas de maíz. Para ello, se comparan las proporciones observadas de semillas germinadas y no germinadas con las proporciones esperadas bajo la hipótesis nula.

(c) (4.0 pt) ¿Cuál de los siguientes sería el estadístico más adecuado para cuantificar la diferencia entre la distribución observada y la esperada, y así evaluar la validez de la hipótesis nula?

- ☐ La media de la cantidad de semillas germinadas.
- ☐ La varianza del número de semillas que no germinan.
- ☐ La distancia total de variación entre las proporciones observadas y esperadas.
- ☐ La suma total de semillas germinadas y no germinadas.
- ☐ La diferencia entre el número observado y esperado de semillas germinadas.

El siguiente histograma representa la distribución de la distancia total de variación (TVD), generada mediante permutaciones aleatorias bajo la hipótesis nula de que la proporción de semillas que germinan es igual al 50%.

El punto rojo indica el valor observado de TVD en el experimento real, donde germinaron 70 de 200 semillas.

(d) (4.0 pt) ¿Cuál es la interpretación más adecuada basada en esta visualización?

- ☐ El valor observado de TVD es típico bajo la hipótesis nula, por lo que no hay razón para rechazar H_0.
- ☐ El valor observado de TVD es inusualmente pequeño bajo la hipótesis nula, lo que sugiere evidencia para rechazar H_0.
- ☐ Como el valor observado de TVD está muy cerca de la media de la distribución nula, hay evidencia de que la hormona es efectiva.
- ☐ La distribución nula está sesgada, por lo tanto no es válida para evaluar el experimento.
- ☐ El valor observado de TVD es grande bajo la hipótesis nula, lo que sugiere evidencia para rechazar H_0.

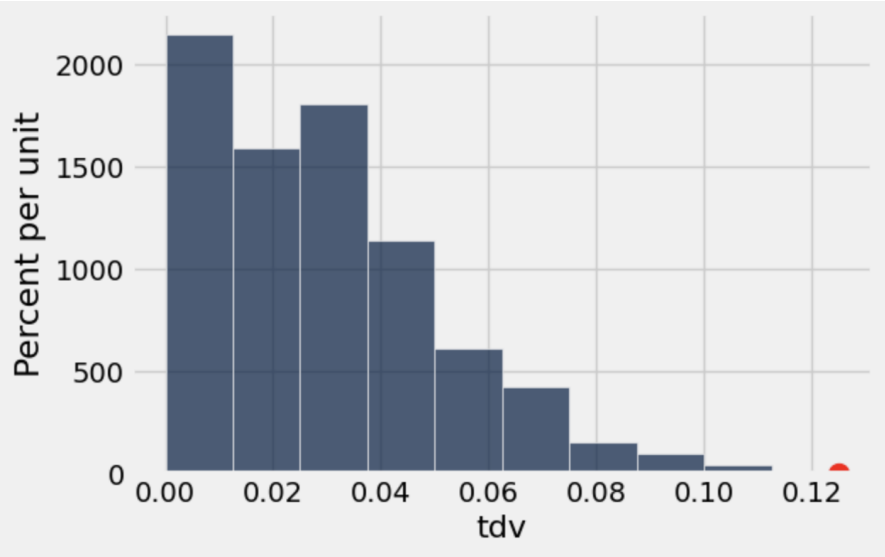

Figure 1: Distribución de TVD bajo H_0 y valor observado (rojo).

A continuación, se presentan una hipótesis nula y una hipótesis alternativa sobre la relación entre el peso al nacer y el hábito de fumar de la madre. Responde la pregunta seleccionando todas las opciones correctas.

(e) (4.0 pt) ¿El siguiente código permitiria recrear el hisrograma anterior?

◯ Verdadero ◯ Falso

```
observado=75/200
prop = make_array(proportions, 1-proportions)
def distancia_separacion(val):
    d = abs(0.5-val)
    return d
d1=distancia_separacion(observado)

aa = make_array()
for i in range(0, 2000):
    u = sample_proportions(200, prop)[0]
    dd = distancia_separacion(u)
    aa=np.append(aa, dd)
tbl = Table().with_column("tdv",aa)

tbl.hist()
plots.plot(d1, 0, "ro", ms=10 )
```

Principales Comandos de la Librería `datascience`

Comando	**Descripción**
`Table.read_table("archivo.csv")`	Carga un archivo CSV como una tabla de datos.
`tabla.show(n)`	Muestra las primeras n filas de la tabla.
`tabla.select("columna1", "columna2")`	Crea una nueva tabla con solo las columnas seleccionadas.
`tabla.drop("columna")`	Crea una nueva tabla eliminando la columna indicada.
`tabla.sort("columna", descending=True)`	Ordena la tabla por la columna especificada en orden descendente.
`tabla.where("columna", are.equal_to(valor))`	Filtra la tabla y muestra solo las filas donde la columna cumple la condición dada.
`tabla.group("columna", np.sum)`	Agrupa los valores por una columna y aplica una función de agregación (ejemplo: suma).
`tabla.apply(funcion, "columna")`	Aplica una función a cada fila de la columna seleccionada.
`tabla.hist("columna")`	Dibuja un histograma de la columna indicada.
`tabla.scatter("columna1", "columna2")`	Genera un gráfico de dispersión entre dos columnas.
`tabla.num_rows`	Devuelve el número de filas en la tabla.
`tabla.num_columns`	Devuelve el número de columnas en la tabla.
`tabla.column("columna")`	Devuelve los valores de una columna como un array.
`tabla.item(fila, "columna")`	Devuelve el valor específico de una celda en la tabla.
`tabla.relabeled("columna_vieja", "columna_nueva")`	Renombra una columna de la tabla.
`tabla.simple_proportion("columna", valor)`	Calcula la proporción de valores iguales a un valor dado.
`tabla.sample(k)`	Selecciona k filas aleatorias de la tabla (con reemplazo por defecto).

Guía Básica de Python

Concepto	**Ejemplo en Python**
Definir una variable	`x = 10`
Listas en Python	`numeros = [1, 2, 3, 4, 5]`
Acceder a un elemento de una lista	`numeros[0]` devuelve 1
Agregar un elemento a una lista	`numeros.append(6)`
Eliminar un elemento de una lista	`numeros.remove(3)`
Estructura condicional	`if x > 5:  print("Mayor a 5")`
Bucle `for`	`for i in range(5):  print(i)`
Bucle `while`	`while x > 0:  x -= 1`
Definir una función	`def suma(a, b):  return a + b`
Importar librerías	`import numpy as np`
Crear un array de NumPy	`arr = np.array([1, 2, 3])`
Filtrar una lista con `list comprehension`	`pares = [x for x in numeros if x % 2 == 0]`
Crear un diccionario	`dicc = {"a":  1, "b":  2}`
Acceder a un valor en un diccionario	`dicc["a"]` devuelve 1
Leer un archivo CSV con Pandas	`import pandas as pd` `df = pd.read_csv("datos.csv")`
Obtener estadísticas descriptivas	`df.describe()`
Filtrar un DataFrame de Pandas	`df[df["columna"] > 10]`