



Universidad de Antioquia
Facultad de Ciencias Exactas y Naturales
Examen 2: Fundamentos en ciencia de datos
(FCD) 25 Marzo 2025

- Nombre :

- E-mail :

- Profesor laboratorio :

Instrucciones del Examen

Este examen debe realizarse de manera estrictamente **individual**. Lea atentamente las siguientes reglas antes de comenzar:

- **Tiempo límite:** La duración del examen es de 110 minutos (1 hora 50 minutos).
- **Formato de respuestas:**
 - Preguntas con **círculos** (○) permiten seleccionar **una única respuesta**.
 - Preguntas con **cuadros** [□] permiten seleccionar **múltiples respuestas**.
- **Uso de materiales externos:** Está completamente prohibido el uso de libros, apuntes, dispositivos electrónicos como calculadoras, teléfonos o computadoras, consultas a otras personas o cualquier forma de colaboración.

Formato del examen:

- Responda directamente en la hoja del examen en los espacios designados. Asegúrese de que sus respuestas sean legibles y definitivas; las respuestas ambiguas o tachadas pueden no ser evaluadas.

Normas de conducta:

- Cualquier intento de fraude o comunicación con otros estudiantes resultará en la anulación inmediata del examen.
- En caso de dudas, consulte únicamente con el supervisor del examen.

Entrega: Al finalizar el tiempo, entregue el examen de inmediato. No se aceptarán exámenes fuera del tiempo asignado.

Lea cuidadosamente cada pregunta y conteste con claridad. ¡Éxito en su examen!

1. (28 puntos) Falso/Verdadero

1. (2.0 pt) Si un diagrama de dispersión tiene un coeficiente de correlación de 1, todos los puntos deben estar perfectamente en una línea recta.
☐ Verdadero ☐ Falso
2. (2.0 pt) Al crear un clasificador, asegurarse de tener un conjunto de entrenamiento grande y diverso es una buena manera de mitigar el sobreajuste.
☐ Verdadero ☐ Falso
3. (2.0 pt) Según el teorema del límite central, si una muestra es grande y se extrae al azar de la población con reemplazo, entonces la distribución de probabilidad de la media muestral es aproximadamente normal.
☐ Verdadero ☐ Falso
4. (2.0 pt) Si usamos una regresión lineal para predecir valores de y basados en nuestros valores de x , donde tanto x como y están estandarizados, el estimado del intercepto podría ser negativo.
☐ Verdadero ☐ Falso
5. (2.0 pt) Si estás muestreando un atributo numérico que solo puede tomar valores de 0 o 1, la desviación estándar de tu muestra podría tener un valor de 0.5.
☐ Verdadero ☐ Falso
6. (2.0 pt) Si usamos regresión lineal para predecir valores de y basados en nuestros valores de x , el promedio de nuestros residuos siempre será cero, independientemente de si x e y están estandarizados.
☐ Verdadero ☐ Falso
7. (2.0 pt) La distancia total de variación solo puede aplicarse a distribuciones categóricas en las que hay 3 o más categorías únicas.
☐ Verdadero ☐ Falso
8. (2.0 pt) La manera recomendada de estimar la precisión de un clasificador en la población es evaluar su precisión en el conjunto de entrenamiento.
☐ Verdadero ☐ Falso
9. (2.0 pt) Para cualquier distribución, el porcentaje de datos que se encuentra dentro de 3 desviaciones estándar del promedio es al menos el 80
☐ Verdadero ☐ Falso
10. (2.0 pt) Al realizar un experimento de control aleatorio, la asignación aleatoria de tratamiento y control sirve como una forma de simular datos de la hipótesis nula.
☐ Verdadero ☐ Falso

11. (2.0 pt) La Regla de Chebychev nos permite modelar creencias subjetivas sobre eventos que involucren aleatoriedad.
- ☐ Verdadero ☐ Falso
12. (2.0 pt) Un ejemplo de un clasificador es el de las redes neuronales modernas. Estas son modelos de aprendizaje automático muy potentes para la clasificación de imágenes debido a que pueden aprender automáticamente características complejas a partir de los datos.
- ☐ Verdadero ☐ Falso
13. (2.0 pt) La razón por la que mezclamos etiquetas en un test A/B es para asegurar que nuestros sujetos se asignen aleatoriamente al tratamiento y control.
- ☐ Verdadero ☐ Falso
14. (2.0 pt) Supongamos que se propone una prueba de hipótesis y ya sabemos que la hipótesis nula es verdadera. Si 500 investigadores recolectan cada uno una muestra del mismo tamaño para realizar un experimento y todos usan un valor p de corte de 1%, deberíamos esperar que alrededor de 5 de ellos rechacen la nula.
- ☐ Verdadero ☐ Falso

2. (12 Pts) Limite central

1. (3. pt) ¿Cuál es la afirmación clave del Teorema del Límite Central?

- ☐ La media de una muestra siempre es igual a la media de la población.
- ☐ Las distribuciones de las medias muestrales se aproximan a una distribución normal a medida que el tamaño de muestra aumenta.
- ☐ Todas las muestras de una población son normales si la población es normal.
- ☐ El tamaño de la muestra no afecta la forma de la distribución muestral.

2. (3. pt) ¿Cuál es una condición necesaria para aplicar el Teorema del Límite Central?

- ☐ La población de la que se extrae la muestra debe ser normal.
- ☐ Las muestras deben ser grandes e independientemente seleccionadas.
- ☐ Solo se puede aplicar a muestras de tamaño fijo.
- ☐ Las muestras deben ser pequeñas y seleccionadas al azar.

3. (3. pt) ¿Qué implica el teorema del límite central respecto a la desviación estándar de las medias muestrales?

- ☐ La desviación estándar de las medias muestrales no tiene relación con la población.
- ☐ Se reduce en función de la raíz cuadrada del tamaño de la muestra.
- ☐ Se incrementa con el tamaño de la muestra.
- ☐ Es igual a la desviación estándar de la población.



4. (3. pt) Si se tiene una muestra suficientemente grande, ¿qué forma tendrá la distribución de la media muestral según el teorema del límite central?

- ☐ Exponencial.
- ☐ Normal.
- ☐ Uniforme.
- ☐ Ninguna de las anteriores.

3.(20 Pts) Regresión lineal

1. (2.0 pt) Al realizar un análisis para inferir la pendiente verdadera, ¿cuál de las siguientes afirmaciones sobre el remuestreo es correcta?
 - ☐ El remuestreo siempre proporciona una distribución normal de pendientes.
 - ☐ El remuestreo con reemplazo ayuda a aproximar la distribución de la pendiente.
 - ☐ El remuestreo solo funciona con grandes conjuntos de datos.
 - ☐ El remuestreo no es necesario si la pendiente es claramente visible.
2. (3.0 pt) ¿Cuál es la función principal del remuestreo al inferir una pendiente verdadera?
 - ☐ Proporcionar un método para verificar la normalidad de los datos.
 - ☐ Estimar la variabilidad de la pendiente obtenida a partir de la muestra.
 - ☐ Reducir la variabilidad de la muestra original.
 - ☐ Aumentar el tamaño de la muestra para que la pendiente sea más visible.
3. (3.0 pt) En el contexto del análisis de pendiente, ¿por qué es importante comparar la pendiente observada con un intervalo de confianza?
 - ☐ Para asegurar que la pendiente observada es una estimación precisa del parámetro de la población.
 - ☐ Para determinar si la pendiente observada está dentro del rango esperado si no hay relación.
 - ☐ Para demostrar que la pendiente observada es mayor que cualquier otra pendiente.
 - ☐ Para mostrar que cualquier pendiente es posible en la muestra.
4. (3.0 pt) ¿Qué interpretación es válida si la pendiente calculada cae fuera del intervalo de confianza esperado al 95%?
 - ☐ La pendiente calculada es definitivamente incorrecta.
 - ☐ Es poco probable que la pendiente observada ocurra debido al azar si no hay relación.
 - ☐ El modelo de regresión está mal especificado.
 - ☐ Los datos deben ser remuestreados más veces.

En un estudio sobre el peso al nacer, se ha empleado un modelo de regresión lineal para predecir el peso basado en el número de días de gestación. La línea amarilla en el gráfico de dispersión representa dicho modelo. Además, se muestra un histograma de las predicciones realizadas para un valor específico de 300 días de gestación, proporcionando una visión de la variabilidad a través del intervalo de confianza.



5. (3.0 pt) Basándote en el histograma de predicciones a los 300 días de gestación, ¿cuál es la afirmación más precisa sobre el intervalo de confianza?

- ☐ El intervalo de confianza refleja la variabilidad esperada en las predicciones del peso al nacer.
 - ☐ El intervalo de confianza garantiza que todas las predicciones estarán centradas en 130.
 - ☐ Las predicciones fuera del intervalo de confianza son imposibles.
 - ☐ El intervalo de confianza asegura que el peso al nacer nunca será inferior a 126.
6. (3.0 pt) Observando el gráfico de dispersión, ¿qué puede deducirse sobre el ajuste del modelo para los datos presentados?
- ☐ El modelo predice con precisión perfecta todos los pesos al nacer.
 - ☐ La línea de regresión se ajusta bien, pero hay variabilidad alrededor de las predicciones.
 - ☐ Todas las observaciones se desvían significativamente de la línea de regresión.
 - ☐ No hay relación entre los días de gestación y el peso al nacer.
7. (3.0 pt) ¿Cuál de las siguientes acciones podría mejorar la precisión del modelo de predicción?
- ☐ Reducir la cantidad de datos utilizados en el modelo.
 - ☐ Considerar más variables explicativas en el modelo, además de los días de gestación.
 - ☐ Usar solo los datos que se ajustan perfectamente a la línea de regresión.
 - ☐ Ignorar cualquier variabilidad observada en los datos.

4. (30 Pts) Spotify

Laura y Camila estuvieron de viaje durante una semana con otras 13 personas. Están interesadas en entender qué canciones escucharon durante este período. Para evaluar esto, seleccionaron al azar las "reproducciones" de canciones de las 15 personas y las colocaron en una tabla llamada `spotify`. Aquí están las primeras filas de la tabla:

Username	Artist	Song	Genre	Duration
laura123	Shakira	Antología	Pop	3.14
camilamusica	Carlos Vives	La Bicicleta	Vallenato	2.78
juanseleguizamo	Cerati	Cactus	Rock	3.05
pepeguardiola	Alice Chain	Nutshell	Rock	4.07

Table 1: Reproducciones durante la semana

Los nombres de las columnas son:

- **Username:** (tipo: str) el nombre de usuario de Spotify de la persona que escuchó la canción
- **Artist:** (tipo: str) el artista de la canción
- **Song:** (tipo: str) el nombre de la canción
- **Genre:** (tipo: str) el género de la canción
- **Duration:** (tipo: float) el número de minutos que se escuchó la canción en esa ocasión

Nota: Hay una fila por cada vez que se reprodujo una canción, por lo que muchas filas se repetirán. Por ejemplo, si Camila escuchó la canción *La Bicicleta* 3 veces, habrá 3 filas en la tabla para esas "reproducciones".

Preguntas

1. (3.0 pt) ¿Cuál de las siguientes expresiones de Python devuelve el nombre del artista con más reproducciones en la tabla? Selecciona todas las que correspondan.

☐ `spotify.sort('Duration', descending=True).column(1).item(0)`

☐ `spotify.group('Artist').sort(1, descending=True).column(0).item(0)`

☐ `spotify.sort('Duration', descending=True).column('Artist').item(0)`

☐ `spotify.select('Artist', 'Duration').group(0, max).sort(1, descending=True).column(0).item(0)`

☐ Ninguna de las anteriores.

2. (3.0 pt) Escribe una expresión de Python que devuelva una tabla con más de 3 columnas que muestre la duración promedio de cada reproducción única por combinación de artista y canción.

3. (3.0 pt) Escribe una expresión de Python que devuelva el nombre del artista que tiene el mayor número de canciones únicas en la tabla.

Aunque observar una tabla de reproducciones de canciones es útil, Laura nota que la tabla no contiene los nombres de las personas que reprodujeron las canciones. Por lo tanto, crea una tabla separada llamada `accounts` que contiene las cuentas de Spotify de sus amigos. Aquí están las primeras filas:

La tabla tiene las siguientes columnas:

Identifier	DisplayName
laura123	Laura Perez
camilamusica	Camila Torres
juanseleguizamo	Juan Segura

Table 2: Cuentas de Spotify de amigos

- **Identifier:** (cadena) el ID de la cuenta en la base de datos de Spotify
 - **DisplayName:** (cadena) el nombre para mostrar de la cuenta (nombre y apellido)
4. Laura nota que uno de sus amigos, 'Carlos Pérez', tiende a saltarse las canciones Pop después de escucharlas solo por unos segundos. Escribe el siguiente código parcialmente completado, que asigna `result` a un arreglo que contiene la duración promedio de cada canción Pop única que Carlos reprodujo:

```
combined = __ (a) __
todd_pop_songs = __ (b) __
result = todd_pop_songs.__ (c) __
```

- (3.0 pt) Escribe una expresión de Python que genere la expresión en (a)

- (3.0 pt) Escribe una expresión de Python que genere la expresión en (b)

- (3.0 pt) Escribe una expresión de Python que genere la expresión en (c)

Camila analizó los datos de las canciones que sus 15 amigos escucharon durante la semana. Notó que las canciones del género 'Pop' tienden a tener una duración promedio más corta que las de 'Hip-Hop'. Esto plantea la pregunta de si esta diferencia es estadísticamente significativa o simplemente una casualidad.

Para investigar esta cuestión, Laura sugiere realizar una prueba de hipótesis para determinar si la diferencia observada en las duraciones promedio es significativa o podría haber surgido por azar.

- **Hipótesis Nula (H0):** No hay una diferencia significativa en la duración promedio de las reproducciones de canciones 'Pop' y 'Hip-Hop'; cualquier diferencia observada puede ser atribuible al azar.
- (3.0 pt) **Hipótesis Alternativas (H1):** Selecciona todas las que correspondan que indiquen una diferencia real en las duraciones promedio:
 - ☐ Las reproducciones de canciones 'Pop' tienen una duración promedio menor que las de 'Hip-Hop'.
 - ☐ Las reproducciones de canciones 'Pop' tienen la misma distribución de duración que las de 'Hip-Hop'.
 - ☐ Todas las reproducciones de canciones 'Pop' tienen una duración menor que todas las de 'Hip-Hop'.
 - ☐ Ninguna de las anteriores.

- (3.0 pt) **Pruebas Estadísticas:** Selecciona todas las que correspondan para evaluar la hipótesis:
 - ☐ La distancia total de variación entre la distribución de duración de las reproducciones de canciones 'Pop' y 'Hip-Hop'.
 - ☐ La diferencia entre la duración promedio de las reproducciones de 'Hip-Hop' y 'Pop'.
 - ☐ La duración promedio de las reproducciones de 'Pop'.
 - ☐ La suma de las duraciones promedio de las reproducciones de 'Hip-Hop' y 'Pop'.
 - ☐ Ninguna de las anteriores.
- (3.0 pt) **Cálculo del Valor P:** Camila ha elegido una estadística de prueba donde valores grandes favorecen la hipótesis alternativa. Ha simulado la estadística muchas veces, almacenando los resultados en un arreglo llamado `test_stats`. Supón que el valor observado de la estadística es 12.1.

Escribe una expresión en Python que devuelva el valor p para esta prueba de hipótesis:

- (3.0 pt) Camila utiliza un nivel de significancia del 5%, lo que corresponde a un valor crítico de la estadística de prueba de 10.2. Si el valor de la estadística observada es 12.1 y excede el valor crítico, ¿cuáles de las siguientes conclusiones son válidas? Selecciona todas las que correspondan.
 - ☐ Los datos son consistentes con la hipótesis nula.
 - ☐ Los datos son consistentes con la hipótesis alternativa.
 - ☐ Hay un 5% de probabilidad de que la hipótesis nula sea verdadera.
 - ☐ Hay un 5% de probabilidad de que la hipótesis alternativa sea verdadera.
 - ☐ Las reproducciones de canciones 'Pop' tuvieron una duración promedio menor que las de 'Hip-Hop'.
 - ☐ No hay suficiente información para llegar a una conclusión de ningún tipo.

5. (10 Pts) Bootstrapping y regresión lineal

Imagina que estás analizando los datos de venta de una pequeña tienda y quieres estimar la mediana del monto de las ventas diarias. Tienes la siguiente tabla de ventas:

```
Ventas
-----
150
200
250
300
350
```

Usa bootstrapping para estimar el intervalo de confianza del 95% para la mediana de las ventas.

Completa el siguiente fragmento de código:

```
from datascience import Table
import numpy as np

# Datos de ventas
ventas = Table().with_columns("Monto", [150, 200, 250, 300, 350])

def bootstrap_median(ventas, repetitions):
    medians = []
    for _ in range(repetitions):
        resample = ventas.sample(with_replacement=True) # Completa esta parte
        median = np.median(resample.column('Monto'))
        medians.append(median)
    return medians

# Calcula el intervalo de confianza
medians = bootstrap_median(ventas, 1000)
lower_bound = -----(a)-----
upper_bound = -----(b)-----
(lower_bound, upper_bound)
```

1. (2.0 pt) Completa el fragmento de código en (a):

2. (2.0 pt) Completa el fragmento de código en (b):

Regresión Lineal

Contexto:

Estás haciendo un análisis para predecir los ingresos anuales de una empresa basándote en su gasto en publicidad. Tienes una tabla con los datos de algunos trimestres anteriores:

Publicidad	Ingresos
50	200
100	400
150	620
200	800
250	1000

Escribe el código necesario para determinar los parametros de la línea de regresión.

```
from datascience import *
import matplotlib.pyplot as plt

# Datos de publicidad e ingresos
datos = Table().with_columns(
    "Publicidad", [50, 100, 150, 200, 250],
    "Ingresos", [200, 400, 620, 800, 1000]
)

def standar_units(x):
    xus = -----(a)-----
    return xus

def calculate_slope(x, y):
    xus = standar_units(x)
    yus = standar_units(y)
    sigmaX = np.std(x)
    sigmaY = np.std(y)

    r = -----(b)-----

    slope=r*sigmaY/sigmaX
    return slope

def calculate_intercept(x, y, slope):
    intercept = -----(c)-----
    return intercept

slope = calculate_slope(datos.column('Publicidad'), datos.column('Ingresos'))
intercept = calculate_intercept(datos.column('Publicidad'), datos.column('Ingresos'), slope)

# Gráfica
datos.scatter('Publicidad', 'Ingresos')
x = np.linspace(0, 300, 100)
y = slope * x + intercept
plt.plot(x, y, color='red', label='Línea de Regresión')
plt.legend()
plt.show()
```

3. (2.0 pt) Completa el fragmento de código en (a) de la función standar_units:

4. (2.0 pt) Completa el fragmento de código en (b) de la función calculate_slope:

5. (2.0 pt) Completa el fragmento de código en (c) de la función calculate_intercept:

Principales Comandos de la Librería datascience

Comando	Descripción
<code>Table.read.table("archivo.csv")</code>	Carga un archivo CSV como una tabla de datos.
<code>tabla.show(n)</code>	Muestra las primeras n filas de la tabla.
<code>tabla.select("columna1", "columna2")</code>	Crea una nueva tabla con solo las columnas seleccionadas.
<code>tabla.drop("columna")</code>	Crea una nueva tabla eliminando la columna indicada.
<code>tabla.sort("columna", descending=True)</code>	Ordena la tabla por la columna especificada en orden descendente.
<code>tabla.where("columna", are.equal.to(valor))</code>	Filtra la tabla y muestra solo las filas donde la columna cumple la condición dada.
<code>tabla.group("columna", np.sum)</code>	Agrupar los valores por una columna y aplica una función de agregación (ejemplo: suma).
<code>tabla.apply(funcion, "columna")</code>	Aplica una función a cada fila de la columna seleccionada.
<code>tabla.hist("columna")</code>	Dibuja un histograma de la columna indicada.
<code>tabla.scatter("columna1", "columna2")</code>	Genera un gráfico de dispersión entre dos columnas.
<code>tabla.num_rows</code>	Devuelve el número de filas en la tabla.
<code>tabla.num_columns</code>	Devuelve el número de columnas en la tabla.
<code>tabla.column("columna")</code>	Devuelve los valores de una columna como un array.
<code>tabla.item(fila, "columna")</code>	Devuelve el valor específico de una celda en la tabla.
<code>tabla.relabeled("columna_vieja", "columna_nueva")</code>	Renombra una columna de la tabla.
<code>tabla.simple_proportion("columna", valor)</code>	Calcula la proporción de valores iguales a un valor dado.
<code>tabla.sample(k)</code>	Selecciona k filas aleatorias de la tabla (con reemplazo por defecto).

Guía Básica de Python

Concepto	Ejemplo en Python
Definir una variable	<code>x = 10</code>
Listas en Python	<code>numeros = [1, 2, 3, 4, 5]</code>
Acceder a un elemento de una lista	<code>numeros[0]</code> devuelve 1
Agregar un elemento a una lista	<code>numeros.append(6)</code>
Eliminar un elemento de una lista	<code>numeros.remove(3)</code>
Estructura condicional	<code>if x > 5: print("Mayor a 5")</code>
Bucle <code>for</code>	<code>for i in range(5): print(i)</code>
Bucle <code>while</code>	<code>while x > 0: x -= 1</code>
Definir una función	<code>def suma(a, b): return a + b</code>
Importar librerías	<code>import numpy as np</code>
Crear un array de NumPy	<code>arr = np.array([1, 2, 3])</code>
Filtrar una lista con <code>list comprehension</code>	<code>pares = [x for x in numeros if x % 2 == 0]</code>
Crear un diccionario	<code>dicc = {"a": 1, "b": 2}</code>
Acceder a un valor en un diccionario	<code>dicc["a"]</code> devuelve 1
Leer un archivo CSV con Pandas	<code>import pandas as pd</code> <code>df = pd.read_csv("datos.csv")</code>
Obtener estadísticas descriptivas	<code>df.describe()</code>
Filtrar un DataFrame de Pandas	<code>df[df["columna"] > 10]</code>