



Universidad de Antioquia
Facultad de Ciencias Exactas y Naturales
Examen 2: Fundamentos en ciencia de datos
(FCD) 29 Enero de 2025

- Nombre :

- E-mail :

- Horarios de laboratorio :

Instrucciones del Examen

Este examen debe realizarse de manera estrictamente **individual**. Lea atentamente las siguientes reglas antes de comenzar:

- **Tiempo límite:** La duración del examen es de 110 minutos (1 hora 50 minutos).
- **Formato de respuestas:**
 - Preguntas con **círculos** (○) permiten seleccionar **una única respuesta**.
 - Preguntas con **cuadros** [□] permiten seleccionar **múltiples respuestas**.
- **Uso de materiales externos:** Está completamente prohibido el uso de libros, apuntes, dispositivos electrónicos como calculadoras, teléfonos o computadoras, consultas a otras personas o cualquier forma de colaboración.

Formato del examen:

- Responda directamente en la hoja del examen en los espacios designados. Asegúrese de que sus respuestas sean legibles y definitivas; las respuestas ambiguas o tachadas pueden no ser evaluadas.

Normas de conducta:

- Cualquier intento de fraude o comunicación con otros estudiantes resultará en la anulación inmediata del examen.
- En caso de dudas, consulte únicamente con el supervisor del examen.

Entrega: Al finalizar el tiempo, entregue el examen de inmediato. No se aceptarán exámenes fuera del tiempo asignado.

Lea cuidadosamente cada pregunta y conteste con claridad. ¡Éxito en su examen!

1. (28 puntos) Falso/Verdadero

1. (2.0 pt) En un estudio biológico se analiza la relación entre la longitud del ala de una especie de ave y su peso corporal, ambos medidos en individuos adultos. El coeficiente de correlación mide la fuerza y dirección de una relación lineal entre dos variables numéricas, y un valor de correlación cercano a cero implica necesariamente que no existe ninguna relación entre la longitud del ala y el peso corporal.

☐ Verdadero ☐ Falso

2. (2.0 pt) En un estudio de ecología, un investigador quiere estimar la longitud promedio de una población de ranas que habita una laguna y para ello selecciona al azar un subconjunto de individuos para medirlos. El hecho de que cada posible subconjunto de ranas tenga la misma probabilidad de ser seleccionado garantiza que la muestra obtenida sea siempre representativa de toda la población de ranas.

☐ Verdadero ☐ Falso

3. (2.0 pt) Un investigador quiere estimar el nivel promedio de una proteína en sangre (por ejemplo, concentración de hemoglobina) en una población de animales. Para ello, toma muchas muestras aleatorias de individuos y calcula la concentración promedio en cada muestra. Sin importar si la distribución de concentraciones individuales en la población es simétrica o sesgada, la distribución de estas medias muestrales será aproximadamente normal si el tamaño de muestra es suficientemente grande.

☐ Verdadero ☐ Falso

4. (2.0 pt) En un estudio de fisiología, un investigador mide la concentración de una hormona en sangre en varios individuos de una población. La desviación estándar se utiliza para cuantificar cuánta variabilidad hay entre las concentraciones medidas respecto al valor promedio. Si la desviación estándar de estas mediciones es igual a cero, entonces todos los individuos tienen exactamente la misma concentración hormonal.

☐ Verdadero ☐ Falso

5. (2.0 pt) Un equipo de investigación quiere evaluar si un nuevo fertilizante aumenta la altura promedio de plantas de frijol. Para ello, asignan al azar algunas plantas al grupo que recibe fertilizante (tratamiento) y otras al grupo que no lo recibe (control), manteniendo las demás condiciones iguales (misma luz, agua y tipo de suelo). La asignación aleatoria ayuda a reducir sesgos y, bajo estas condiciones, permite interpretar como causal cualquier diferencia observada en la altura promedio entre los

grupos.

☐ Verdadero ☐ Falso

6. (2.0 pt) Un investigador compara la expresión promedio de un gen entre dos grupos de células bajo una hipótesis nula que afirma que no hay diferencia real entre ellos. Para evaluar la evidencia contra esta hipótesis, se calcula un valor p . En este contexto, el valor p mide la probabilidad de que la diferencia observada en la expresión génica haya ocurrido solo por azar si la hipótesis nula fuera cierta, y un valor pequeño indica evidencia en contra de dicha hipótesis.

☐ Verdadero ☐ Falso

7. (2.0 pt) En un experimento biológico tipo A/B, se comparan dos tratamientos distintos aplicados a cultivos celulares para evaluar su efecto sobre la tasa de crecimiento. Para simular lo que ocurriría si no hubiera diferencia real entre los tratamientos, se barajan aleatoriamente las etiquetas de los grupos. Este barajado de etiquetas genera datos bajo la hipótesis alternativa.

☐ Verdadero ☐ Falso

8. (2.0 pt) En un estudio de ecología, un investigador compara la distribución de especies observadas en dos hábitats distintos utilizando una medida de distancia entre distribuciones categóricas. La distancia de variación total cuantifica cuán diferentes son estas distribuciones y su valor máximo posible es 1.

☐ Verdadero ☐ Falso

9. (2.0 pt) En un estudio de fisiología, se mide la frecuencia cardíaca de un grupo de animales y se decide estandarizar esta variable para facilitar comparaciones entre individuos. Estandarizar la frecuencia cardíaca implica restarle su media y dividirla por su desviación estándar, de modo que la variable resultante tiene media 0 y desviación estándar 1.

☐ Verdadero ☐ Falso

10. (2.0 pt) En un análisis de regresión lineal, un biólogo estudia la relación entre la masa corporal y el consumo de oxígeno en animales, luego de estandarizar ambas variables. En este caso, el intercepto del modelo de regresión es siempre exactamente cero, independientemente de la relación entre las variables.

☐ Verdadero ☐ Falso

11. (2.0 pt) Un investigador no conoce la forma de la distribución de los datos, pero quiere asegurar

un porcentaje mínimo de observaciones cercanas al promedio. La Regla de Chebyshev proporciona un límite mínimo sobre la proporción de datos dentro de cierto número de desviaciones estándar, y solo es válida para distribuciones normales.

☐ Verdadero ☐ Falso

12. (2.0 pt) Un investigador utiliza una muestra de individuos para estimar la media de una característica heredable y decide aplicar el método bootstrap. El bootstrap es un método de remuestreo con reemplazo que permite aproximar la distribución de un estadístico sin conocer la distribución poblacional.

☐ Verdadero ☐ Falso

13. (2.0 pt) Se utiliza un modelo para predecir si una célula pertenece a un tipo celular específico a partir de sus características moleculares. Un clasificador es un modelo que predice etiquetas categóricas, y la regresión lineal es un ejemplo de este tipo de modelo.

☐ Verdadero ☐ Falso

14. (2.0 pt) En un estudio fisiológico se observa que a medida que aumenta la edad de un organismo, disminuye la tasa metabólica, lo que da lugar a una correlación negativa entre ambas variables. Esto implica necesariamente que el envejecimiento causa la disminución de la tasa metabólica.

☐ Verdadero ☐ Falso

15. (2.0 pt)(Seleccione una) Un grupo de biólogos toma una muestra aleatoria de individuos de una población y construye un intervalo de confianza del 95% para la media poblacional de una característica biológica (por ejemplo, la concentración promedio de una hormona). Una vez calculado el intervalo, ¿cuál de las siguientes afirmaciones describe correctamente lo que significa el nivel de confianza del 95%?

2. (15 Pts) Teorema del Límite Central e Intervalos de Confianza

Un laboratorio de biología estudia una especie de pez en un lago y está interesado en dos cosas: (i) estimar el promedio poblacional de un biomarcador (por ejemplo, la concentración de cortisol en sangre), y (ii) evaluar si un **tratamiento** (cambio en la dieta) afecta ese biomarcador. Como no pueden medir a todos los peces del lago, toman muestras aleatorias y usan inferencia estadística.

1. (3. pt) El laboratorio construye un intervalo de confianza del 95% para la media poblacional de cortisol en el lago a partir de una muestra aleatoria de peces. ¿Cuál interpretación es correcta?

- ☐ Aproximadamente el 95% de los peces del lago tienen niveles de cortisol dentro de ese intervalo.
- ☐ Si repitiéramos el muestreo muchas veces y construyéramos un intervalo del 95% cada vez, cerca de 95 de cada 100 intervalos incluirían la media poblacional verdadera.
- ☐ Hay un 95% de probabilidad de que la media poblacional verdadera esté dentro de *este* intervalo una vez ya fue calculado.
- ☐ El intervalo siempre contiene la media poblacional verdadera, sin importar la muestra.

2. (3. pt) Para comparar el cortisol entre peces con dieta A y dieta B, el laboratorio plantea una hipótesis nula: *“la dieta no cambia el cortisol promedio”*. Tras recolectar datos, obtienen un valor- p de 0.02. ¿Qué significa correctamente este resultado?

- ☐ Que la hipótesis nula tiene probabilidad 0.02 de ser verdadera.

- ☐ Que observar una diferencia como la encontrada (o más extrema) sería poco probable si la hipótesis nula fuera cierta.

- ☐ Que la hipótesis alternativa tiene probabilidad 0.98 de ser verdadera.

- ☐ Que se ha demostrado con certeza que la dieta causa el cambio en cortisol.

3. (3. pt) El laboratorio decide usar un nivel de significancia $\alpha = 0.05$ para tomar una decisión sobre la hipótesis nula. ¿Cuál regla de decisión es correcta?

- ☐ Si $p > \alpha$, se rechaza la hipótesis nula.

- ☐ Si $p < \alpha$, se rechaza la hipótesis nula.

- ☐ Si $p = \alpha$, se acepta automáticamente la hipótesis alternativa.

- ☐ Si $p < \alpha$, entonces la hipótesis nula es verdadera con probabilidad $1 - \alpha$.

4. (3. pt) En el estudio, la **media verdadera** de cortisol de todos los peces del lago es un número fijo pero desconocido. En cambio, la media calculada con una muestra de peces puede variar si se toma otra muestra diferente. ¿Cuál afirmación es correcta?

- ☐ La media poblacional es una estadística porque se calcula con una muestra.


- ☐ La media muestral es un parámetro porque describe a toda la población del lago.
- ☐ La media poblacional es un parámetro y la media muestral es una estadística.
- ☐ La media muestral y la media poblacional siempre son iguales si el muestreo es aleatorio.

(3. pt) Antes de construir intervalos de confianza o realizar pruebas de hipótesis, el laboratorio toma una muestra aleatoria de peces y calcula la media del cortisol en esa muestra. ¿Cuál de las siguientes afirmaciones describe correctamente el papel del Teorema del Límite Central?

- ☐ Garantiza que los valores individuales de cortisol en la población sigan una distribución normal.
- ☐ Indica que, para muestras suficientemente grandes, la distribución de la media muestral de cortisol será aproximadamente normal, independientemente de la forma de la distribución poblacional.
- ☐ Asegura que la media muestral es igual a la media poblacional verdadera.
- ☐ Permite que la media poblacional verdadera varíe de una muestra a otra.

3. (14 Pts) Regresión lineal

En un estudio de salud perinatal, se utiliza regresión lineal para modelar la relación entre días de gestación (variable x) y peso al nacer (variable y). La figura de la izquierda muestra el diagrama de dispersión y la recta de regresión ajustada. La figura de la derecha muestra un histograma de predicciones del peso al nacer en $x = 300$ obtenidas al repetir un procedimiento de remuestreo.



1. (2.0 pt) ¿qué representa la **pendiente** de la recta de regresión?

- ☐ El peso promedio al nacer en toda la población.
- ☐ El cambio esperado en el peso al nacer por cada día adicional de gestación.
- ☐ La variabilidad total de los pesos al nacer.

- ☐ La probabilidad de que el bebé nazca con peso normal.

2. (2.0 pt) Para aproximar la distribución de la pendiente estimada a partir de la muestra, una estrategia apropiada es:

- ☐ Ordenar los datos por días de gestación y volver a ajustar.
- ☐ Tomar muchas muestras con reemplazo del conjunto de datos y recalcular la pendiente cada vez.
- ☐ Eliminar los puntos alejados de la recta y recalcular la pendiente.
- ☐ Usar solo una muestra grande y asumir que la pendiente es exacta.

3. (2.0 pt) ¿Cuál es el propósito principal de construir un intervalo (por ejemplo, al 95%) para la pendiente mediante remuestreo?

- ☐ Forzar que la pendiente sea positiva.
- ☐ Medir la incertidumbre de la pendiente estimada debido al muestreo.
- ☐ Asegurar que los datos sean normales.
- ☐ Aumentar el número de observaciones reales del estudio.

4. (2.0 pt) Si un intervalo de confianza al 95% para la pendiente incluye el 0, ¿cuál es la conclusión más razonable?

- ☐ Se demuestra que no existe relación entre días de gestación y peso al nacer.
- ☐ Con estos datos, una pendiente nula es plausible; no hay evidencia clara de relación lineal.
- ☐ La pendiente observada es necesariamente un error.
- ☐ Se debe aumentar el número de remuestreos hasta que el 0 desaparezca.

5. (2.0 pt) Con base en el histograma de predicciones para $x = 300$, ¿qué describe mejor el rango donde cae la mayor parte de las predicciones?

- ☐ La variabilidad de las predicciones del modelo en $x = 300$ cuando se repite el procedimiento de remuestreo.
- ☐ Un conjunto de valores imposibles para el peso al nacer.
- ☐ La distribución exacta de pesos al nacer de toda la población.
- ☐ Una garantía de que todos los bebés con 300 días de gestación pesan lo mismo.

6. (2.0 pt) Observando el diagrama de dispersión, ¿cuál afirmación es más consistente con lo mostrado?

- ☐ La recta explica perfectamente todos los puntos (residuos cero).

- ☐ Hay tendencia positiva, pero existe variabilidad alrededor de la recta (residuos no cero).
- ☐ No hay ninguna relación entre x y y .
- ☐ Todos los puntos deberían estar exactamente sobre la recta si el modelo es correcto.

7. (2.0 pt) ¿Cuál cambio suele ayudar a mejorar la capacidad predictiva del modelo (si está justificado por el contexto)?

- ☐ Usar menos datos para que el modelo “no se confunda”.
- ☐ Agregar variables relevantes (por ejemplo, edad materna, controles prenatales, etc.) y evaluar el desempeño con datos de prueba.
- ☐ Eliminar todas las observaciones que no caen sobre la recta.
- ☐ Ajustar una recta distinta para cada punto observado.

4. (25 Pts) Programa de Monitoreo de Aves Urbanas

Ana y Diego participan en un programa de monitoreo de aves en parques urbanos. Durante una semana, registraron las observaciones realizadas por 12 voluntarios en distintos parques de la ciudad. Cada fila de la tabla corresponde a una observación individual de un ave.

Los datos se almacenaron en una tabla llamada `birds`. A continuación se muestran las primeras filas:

Las columnas de la tabla son:

- **ObserverID:** (str) identificador del voluntario
- **Species:** (str) especie observada
- **Park:** (str) parque donde se realizó la observación
- **TimeOfDay:** (str) momento del día (Mañana, Tarde)
- **Count:** (int) número de aves observadas

1. (3.0 pt) ¿Cuál de las siguientes expresiones de Python devuelve el nombre del parque con el mayor número total de aves observadas? Selecciona todas las que correspondan.

- ☐ `birds.group('Park', sum).sort(1, descending=True).column(0).item(0)`
- ☐ `birds.sort('Count', descending=True).column('Park').item(0)`
- ☐ `birds.group('Park').sort(1, descending=True).column(0).item(0)`

☐ `birds.select('Park', 'Count').group(0, sum).sort(1, descending=True).column(0).item(0)`

2. (2.0 pt) Escribe una expresión de Python que devuelva una tabla con al menos tres columnas que muestre el número promedio de aves observadas por combinación de especie y parque.

3. (2.0 pt) Escribe una expresión de Python que devuelva el identificador del observador que registró observaciones en el mayor número de parques distintos.

Ana también dispone de una tabla llamada `volunteers` con información adicional:

- **ObserverID:** (str) identificador del voluntario
- **Name:** (str) nombre completo

Ana quiere analizar las observaciones hechas por el voluntario llamado Diego López durante la mañana. Completa el siguiente código para que

`result` sea un arreglo con el promedio de aves observadas por especie:

```
combined = __(a)__  
diego_morning = __(b)__  
result = diego_morning.__(c)__
```

4. (2.0 pt) Escribe la expresión correspondiente a (a)

5. (2.0 pt) Escribe la expresión correspondiente a (b)

6. (2.0 pt) Escribe la expresión correspondiente a (c)

7. (3.0 Pts) Diego observa que en el **Parque Norte** se registran menos aves en la **tarde** que en la **mañana**. Para investigar si esta diferencia es real o producto del azar, Ana propone una prueba de hipótesis.

- **Hipótesis Nula (H0):** No hay diferencia en el número promedio de aves observadas en el Parque Norte entre la mañana y la tarde.
- **Hipótesis Alternativas (H1):** Selecciona todas las que correspondan.

- ☐ En promedio, se observan menos aves en la tarde que en la mañana en el Parque Norte.
- ☐ Las distribuciones de conteo de aves en ambos horarios son idénticas.
- ☐ Todas las observaciones de la mañana son mayores que las de la tarde.
- ☐ Ninguna de las anteriores.

8. (3.0 pt) **Estadísticas de Prueba:** Selecciona todas las que podrían usarse para evaluar esta hipótesis.

- ☐ La diferencia entre el promedio de aves observadas en la mañana y en la tarde.
- ☐ La distancia total de variación entre ambas distribuciones.
- ☐ El promedio de aves observadas en la mañana.
- ☐ La suma de los promedios de aves observadas en ambos horarios.
- ☐ Ninguna de las anteriores.

9. (3.0 pt) Se simula la estadística de prueba bajo la hipótesis nula y se almacenan los resultados en un arreglo llamado `simulated_stats`. Supón que el valor observado de la estadística es 4.6 y que valores grandes favorecen la hipótesis alternativa.

Escribe una expresión en Python que calcule el valor- p :

10. (3.0 pt) Camila utiliza un nivel de significancia del 5%. Bajo la hipótesis nula, este nivel de significancia determina un umbral de rechazo de 3.9 para la estadística de prueba. Si el valor observado de la estadística es 4.6, ¿cuáles conclusiones son válidas? Selecciona todas las que correspondan.

- ☐ Los datos son consistentes con la hipótesis nula.
- ☐ Los datos son consistentes con la hipótesis alternativa.
- ☐ Hay un 5% de probabilidad de que la hipótesis nula sea verdadera.
- ☐ Hay evidencia estadística de una diferencia real entre mañana y tarde.
- ☐ No hay suficiente información para sacar conclusiones.

5. (18 Pts) Bootstrapping

Un equipo de investigadores en educación analiza el rendimiento de estudiantes en un examen estandarizado. A partir de una muestra pequeña de estudiantes, se registraron los siguientes puntajes (sobre 100):

Puntaje

58
62
70
75
90

El interés principal del estudio no es la media ni la

mediana, sino la diferencia entre el puntaje máximo y el mínimo observados (rango), como una medida de dispersión del rendimiento académico. Para cuantificar la incertidumbre asociada a esta estimación, los investigadores deciden utilizar bootstrapping.

1. (3.0 pt) ¿Cuál de las siguientes expresiones calcula correctamente el estadístico de interés (rango) a partir de una muestra bootstrap de los puntajes?

- ☐ `np.mean(sample)`
- ☐ `np.median(sample)`
- ☐ `np.max(sample) - np.min(sample)`
- ☐ `np.std(sample)`

2. (3.0 pt) Se generan muchas muestras bootstrap y se calcula el rango para cada una de ellas, obteniendo así una distribución bootstrap del rango. ¿Cuál de las siguientes afirmaciones describe correctamente la información que proporciona esta distribución?

- ☐ La distribución real del rango en la población de estudiantes.
- ☐ La variabilidad del rango estimado debido al muestreo aleatorio.
- ☐ La probabilidad de que el rango poblacional sea mayor que cero.
- ☐ El valor exacto del rango poblacional verdadero.

3. (3.0 pt) Supón que, en lugar de una muestra de 5 estudiantes, el estudio se realiza con una muestra mucho más grande, manteniendo el mismo procedimiento de bootstrapping. ¿Qué efecto tendría esto sobre la distribución bootstrap del rango?

- ☐ Se volvería más dispersa.
- ☐ Permanecería exactamente igual.
- ☐ Se volvería más concentrada alrededor del valor estimado.
- ☐ El bootstrapping dejaría de ser válido.

4. (9.0 pt) Los investigadores quieren usar **bootstrapping** para estimar la variabilidad del **rango** (máximo – mínimo) de los puntajes. Completa el siguiente código para que **ranges** contenga los rangos calculados a partir de muestras bootstrap.

```
from datascience import *
import numpy as np

scores = Table().
    with_column('Puntaje',
        make_array(58, 62, 70, 75, 90))

def bootstrap_range(tbl, reps):
    ranges = make_array()
    for _ in np.arange(reps):
        resample = __(a)__
        r =
            np.max(resample.column('Puntaje'))-__(b)__
        ranges = np.append(ranges, r)
    return ranges

ranges = bootstrap_range(scores, 5000)

interval =
make_array(__(c)__, percentile(97.5, ranges))
interval
```

- (3 pt) Completa (a):

- (3 pt) Completa (b):

- (3 pt) Completa (c):

Principales Comandos de datascience

Comando	Descripción
<code>Table.read_table("..")</code>	Cargar archivo CSV.
<code>tabla.show(n)</code>	Ver primeras n filas.
<code>tabla.select("c1", "c2")</code>	Seleccionar columnas.
<code>tabla.drop("col")</code>	Eliminar columna.
<code>tabla.where("col", cond)</code>	Filtrar filas por condición.
<code>tabla.sort("col", descending=True)</code>	Ordenar tabla.
<code>tabla.group("col", np.mean)</code>	Agrupar y promediar.
<code>tabla.apply(func, "col")</code>	Aplicar función a una columna.
<code>tabla.with_column("n", vals)</code>	Agregar columna nueva.
<code>tabla.relabeled("old", "new")</code>	Renombrar columna.
<code>tabla.take(indices)</code>	Tomar filas por índice(s).
<code>tabla.column("col")</code>	Extraer columna (arreglo).
<code>tabla.num_rows</code>	Número de filas.
<code>tabla.num_columns</code>	Número de columnas.
<code>tabla.hist("col")</code>	Histograma.
<code>tabla.scatter("x", "y")</code>	Dispersión.
<code>tabla.join("col", otra)</code>	Unir dos tablas.
<code>tabla.sample(k, with_replacement=True)</code>	Muestra aleatoria con reemplazo.

Guía Básica de Python

Concepto	Ejemplo
Variable	<code>x = 10</code>
Lista y acceso	<code>nums=[1,2,3], nums[0]</code>
Agregar / eliminar	<code>nums.append(6), nums.remove(3)</code>
Condicional	<code>if x>5: ...</code>
Bucle for	<code>for i in range(5): ...</code>
Función	<code>def suma(a,b): ...</code>
Importar librerías	<code>import numpy as np</code>
Arreglo NumPy	<code>np.array([1,2,3])</code>
List comprehension	<code>[x for x in nums if x%2==0]</code>
Diccionario	<code>d={"a":1}, d["a"]</code>

Guía Rápida: Pruebas de Hipótesis

H_0 : ausencia de efecto o diferencia.

H_1 : existe efecto o diferencia (direccional o no).

Estadística de prueba: número que resume evidencia contra H_0 .

Nivel α : umbral (p.ej. 0.05) para rechazar H_0 .

Valor- p : qué tan extremo es lo observado si H_0 fuera cierta.

Decisión: si $p < \alpha$, rechazar H_0 ; si $p \geq \alpha$, no rechazar H_0 .

Nota: rechazar H_0 no significa que H_0 tenga probabilidad α ni garantiza causalidad.